MISHIMA.SYK#18 ONLINE 2022.04.16

## KNIMEをSlurmで動かす話

@tkochi0603

#### 自己紹介:@tkochi0603

伊豆半島にある製薬会社で、ITインフラ周りを

担当してます



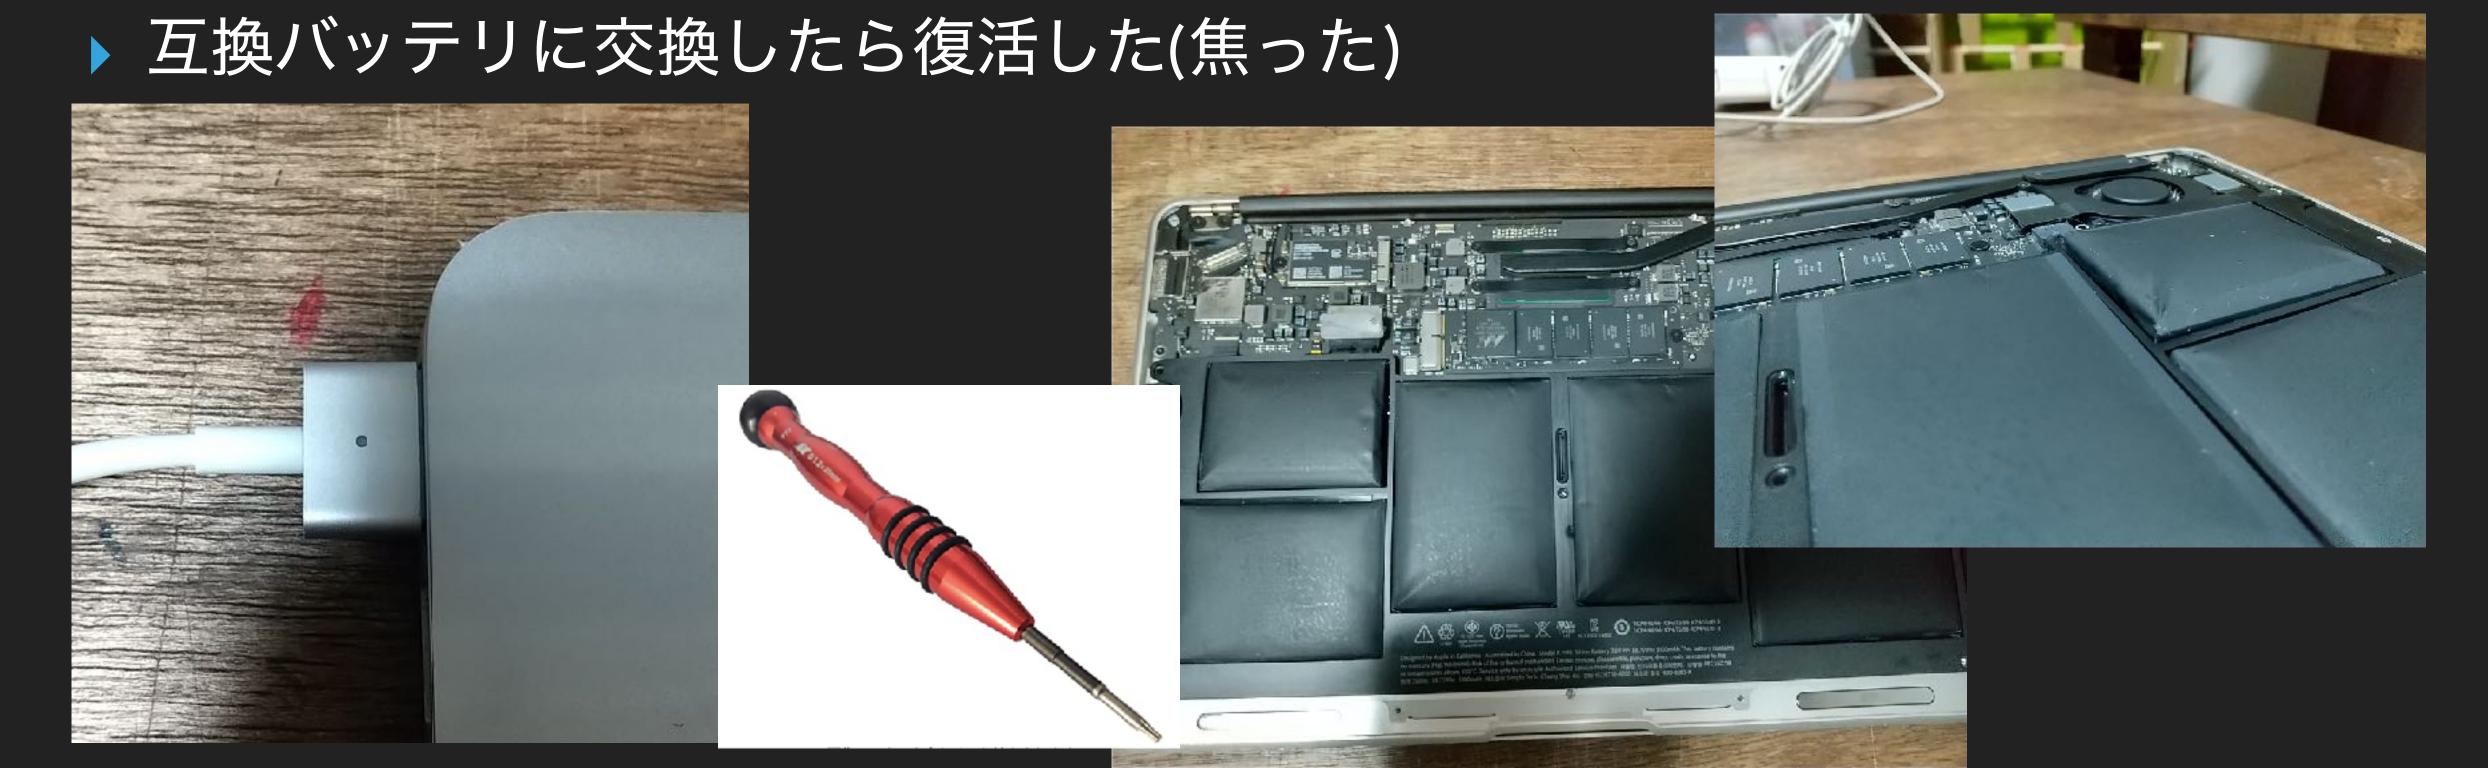




▶ 今月、特急A列車で行こうに乗った。とっても良かった

#### 小話:ある日、

- Mac book Air(A1465:2013年)が充電できなくなりました
- ▶ 星型ドライバを買って開けてみたら、バッテリーが超膨張してた



#### 今日の話

- ▶ Q. KNIME Analyticsで書かれた処理を、スケールアップ したいときどうする?
  - ▶最近のPCはスペックいいし、杞憂かもしれません

#### Q. KNIMEのスケールアップ

- NA1. KNIME Analyticsを動かすPCのスペックを上げる
  - それでもいいけど



#### KNIME Server Small for AWS

By **KNIME** | Ver 4.14.1

44 external reviews

#### Free Trial

Starting from \$2.07/hr or from \$14,500.00/yr (20% savings) for software + AWS usage fees

Use KNIME Analytics Platform to automate advanced analytics, machine learning, or data prep/ETL tasks. Productionize your data science team with collaboration and automation to accelerate delivery and deployment. Using the KNIME Server Small for AWS is a fast and efficient way to power and govern...

#### Q. KNIMEのスケールアップ

- A2. KNIME Serverを大きめなサーバで動かす?
  - NNIME Server持ってないし。。買う?
  - うちも買ったほうがいいかもと、思うけど、クラスタサーバで 動かすとなると金かかりそう

ライセンスプラン	KNIME Server Small	KNIME Server Medium	KNIME Server Large
	少人数のチームで、 リモートでワークフ ローを共有	Webノフソリからソ	複数マシンへのイン ストール、大規模な チームで、グローバ ルなコラボレーショ ン
インストール可能数	1	1	複数台

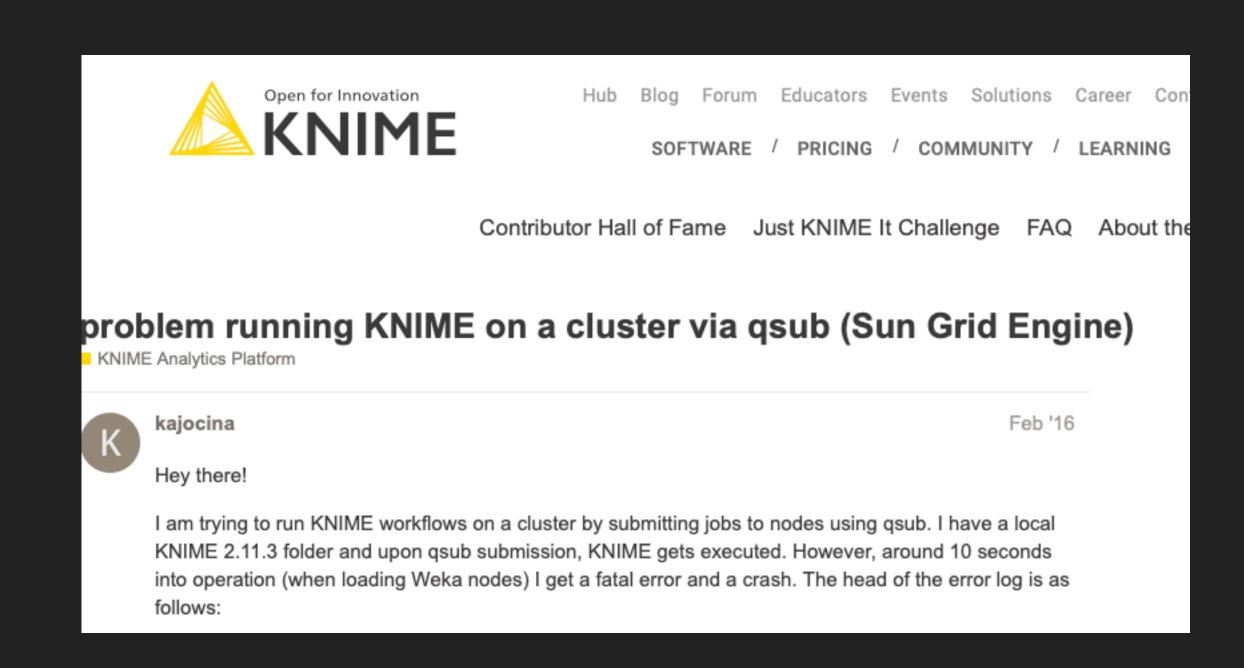
#### Q. KNIMEのスケールアップ

- ▶ A3. 他の言語に書き換えて、クラスタサーバで動かす?
  - 書き換えるのめんどくさいw、けど、やるかも

#### Q. KNIMEのスケールアップ

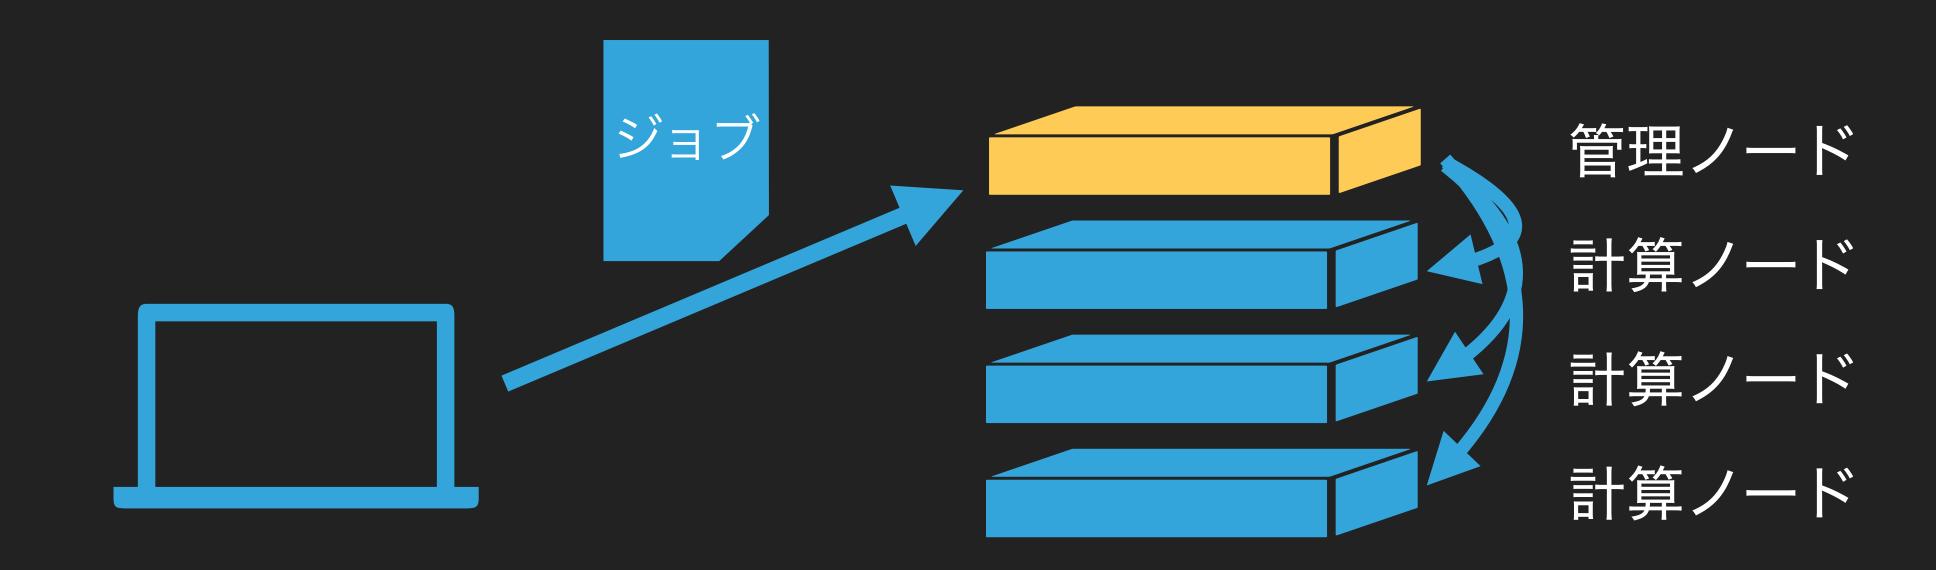
- NA4. KNIME Analyticsをクラスタサーバで動かす
  - とうやら過去にも取り組んでいた人はいるみたい

やってみることにした



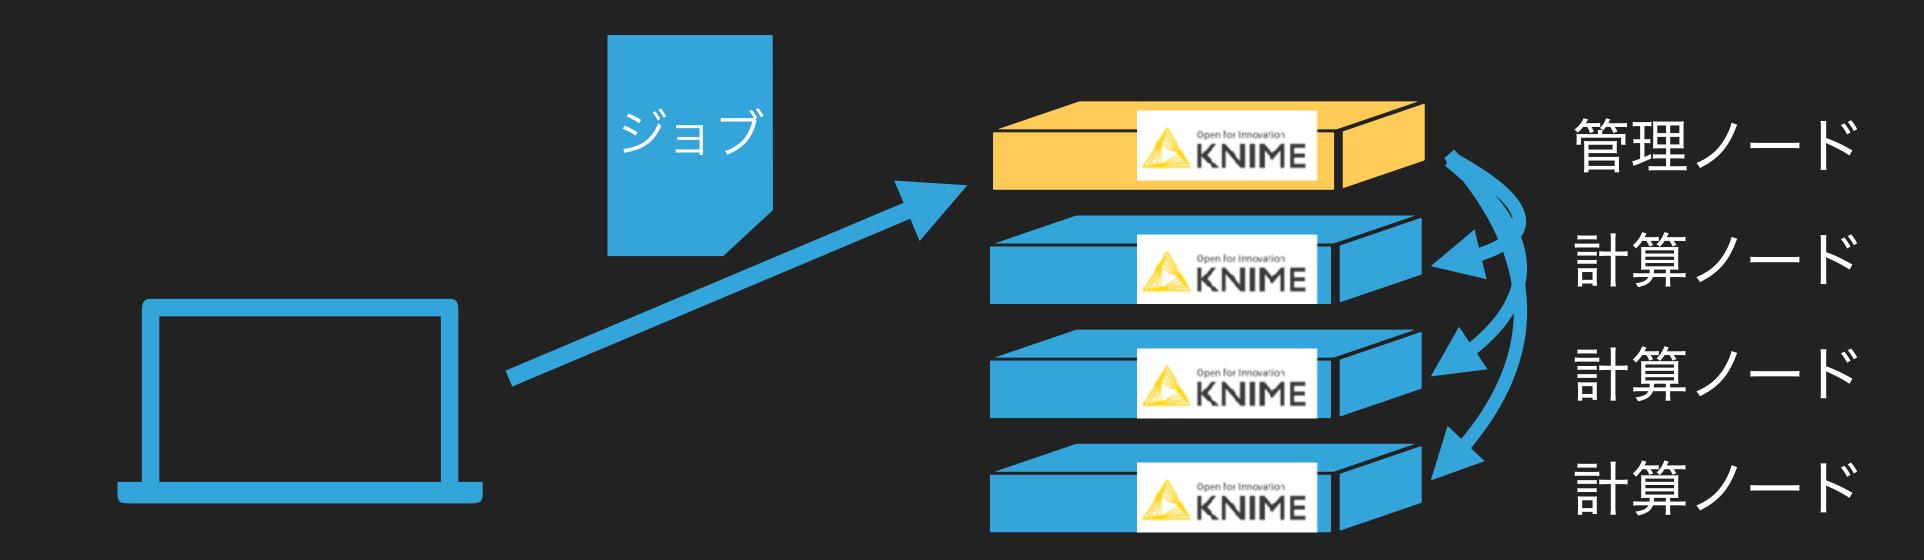
#### ところで、クラスタサーバって?

- ▶ ジョブを制御する管理ノード(PC)と、計算ノード(PC)からなる
- 管理ノードに、ジョブリストを渡すと、空いてる計算ノードにジョブを 割り振って実行させる



#### ってことで、

▶ 各計算ノードで、KNIMEのBATCHモードを動かすことにした





クラスタサーバの構築

# Slurm

#### クラスタサーバの構築

あるある??

- ▶ まだ使えるPC(ガラクタ)が、手元に結構余ってしまった
  - ▶ 留学する人が残していった自作PCクラスタ
  - トクラウド移行して抜け殻となったサーバ
  - トEOLを迎えてVerUpが必要になったOSのサーバ
- トガラクタで組んでみる

#### クラスタサーバのソフトウェア

- ▶ 昔は、Sun(Son) Grid Engine、PBS、Torqueでクラスタサーバを組んで いたけど、最近はSlurmらしい
  - ▶ AWSのParallel ClusterもSlurmを採用している

クラウドとオンプレで、同じ 作法に揃えられますね



#### Slurmで構築する

Ubuntuのパッケージがあったので、全てaptでインストール

計算ノードの制御 Slurmd 全ノードにインストール

Slurmctld 管理ノードにインストール ジョブの管理

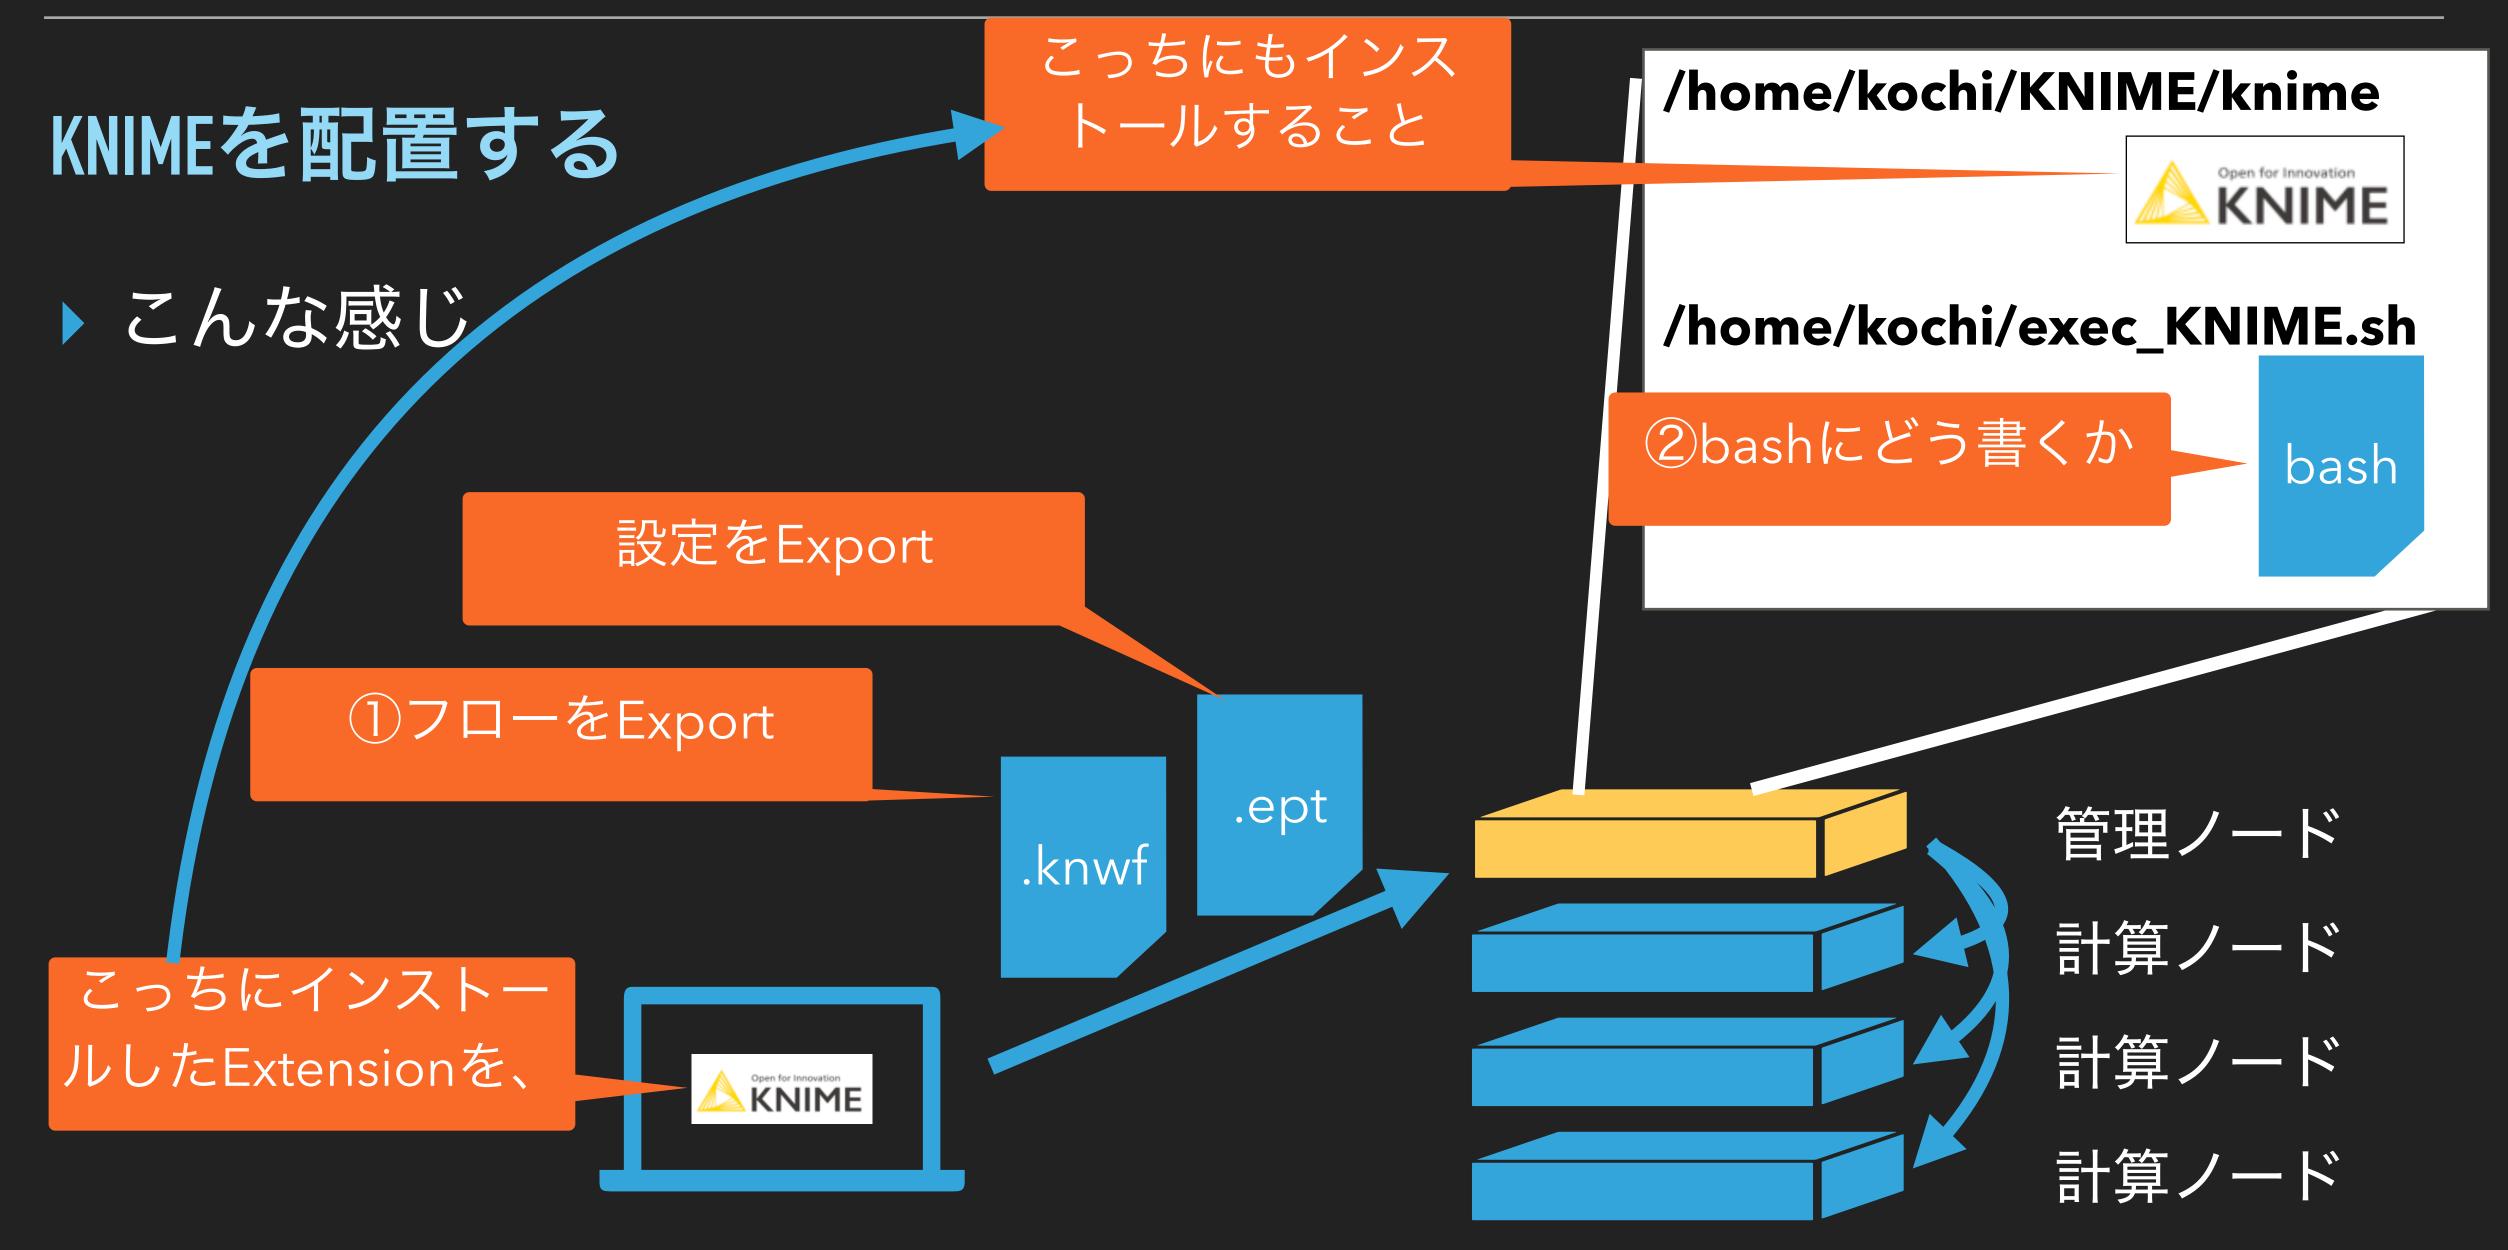
認証

Munge 全ノードにインストール

- > slurm.confとmunge.confとサービスの設定
- ▶ 管理ノードの/homeを、計算ノードが/homeとしてマウント
- ▶ pidファイル関連の設定に手こずる
- ▶ あとは、台数増えたらansibleを使う

GridEngineよりも若干 楽な気がする

ってなことで、Slurmで構築できたとさ

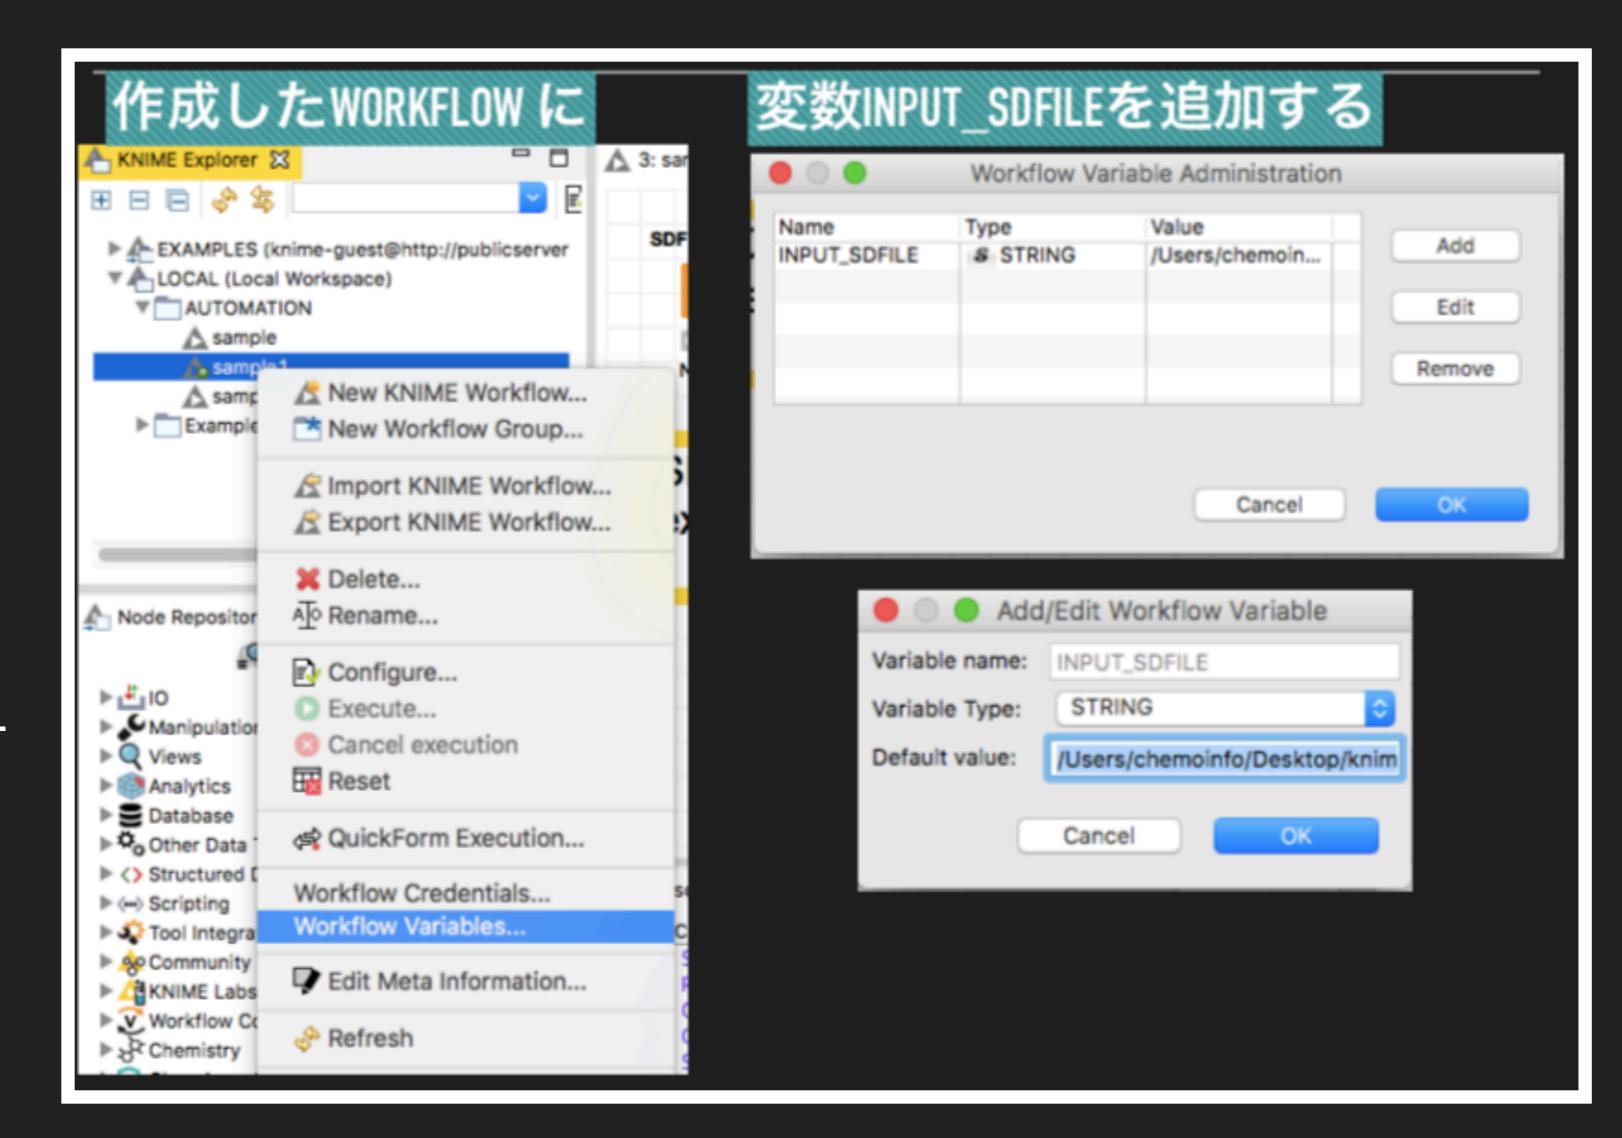




## もう少しだ

#### 1フローをEXPORT

- Workflow Variablesに、入力と 出力の変数を設定しておく
- 詳しくは、私が2017年のMishima.syk #10で紹介した資料や、ググればありますね
  - https://github.com/Mishima-syk/10/blob/master/ KNIME\_batch\_mode\_20170 709\_kochi.pdf



#### ②Bashにどう書くか

#! /bin/bash #SBATCH -p TEST\_QUEUE #SBATCH -o TEST\_%j.stdout #SBATCH -e TEST\_%j.stderr #SBATCH --job-name="TEST\_JOB"

Slurmから受け取る変数

ここがポイント! フォルダを指定すると、フォルダに ロックがかかり、複数同時に起動で きない

Exportしたフローファイル

#### WORKFLOWFILE=/home/kochi/Work/sample.knwf

OPTFILE=/home/kochi/Work/pref\_20220410.epf

PARAM01=/home/kochi/Work/inp01.csv

PARAM02=/home/kochi/Work/out01.csv

Exportした設定ファイル

実行してるのはこの行だけ。他の行は変数

/home/chemoinfo/KNIME/knime\_4.5.2/knime -nosplash -reset -nosave -launcher.suppressErrors -application org.knime.product.KNIME\_BATCH\_APPLICATION preferences=\${OPTFILE} -workflowFile=\${WORKFLOWFILE} workflow.variable=INP\_FILE\_PATH,\${PARAM01},String workflow.variable=OUT\_FILE\_PATH,\${PARAM02},String

### ②Bashにどう書くか'

**C**",

> sbatch exec\_ENIME.sh

と、実行すれば動作するけど、1ジョブを1ノードで実行するだけなので、

#### ②Bashにどう書くか"

```
#! /bin/bash
#SBATCH -p TEST_QUEUE
#SBATCH -o TEST_%j.stdout
#SBATCH -e TEST_%j.stderr
#SBATCH --job-name="TEST_JOB"
```

#### WORKFLOWFILE=/home/kochi/Work/sample.knwf

OPTFILE=/home/kochi/Work/pref\_20220410.epf

/home/chemoinfo/KNIME/knime\_4.5.2/knime -nosplash -reset -nosave -launcher.suppressErrors -application org.knime.product.KNIME\_BATCH\_APPLICATION preferences=\${OPTFILE} -workflowFile=\${WORKFLOWFILE} workflow.variable=INP\_FILE\_PATH,\${PARAM01},String workflow.variable=OUT\_FILE\_PATH,\${PARAM02},String

#### ②Bashにどう書くか"

と、変更して、

> sbatch exec\_ENIME.sh /home/kochi/input\_1.csv /home/kochi/output\_1.csv

引数を渡すようにしておいてから、

for ia in `seq 0 9`; do sbatch exec\_ENIME.sh /home/kochi/input\_\$ia.csv /home/kochi/output\_\$ia.csv done

などと、実行することで、10並列でKNIMEを実行できる

#### まとめ

- ▶ KNIME AnalyticsをCluster Serverで並列実行できる
- ▶が、bashは必要w
- ▶ なので、大規模で計算したいKNIMEerが次に学ぶべき言語はbash ですね。
- **あと、** 
  - ▶ Mishima.syk が、気軽にLTできる会になるといいなと思ってます。
  - ▶ 社内に理解してくれる人が少ないようなトピックスを、社外の人と話して、情報交換。
- Ubuntu 22.04 LTSが来週リリースされる

Ubuntu 22.04 LTS (Jammy Jellyfish) Beta